

Usines logicielles basées sur l'IA

Panorama des architectures, critères de choix et trajectoire de mise en oeuvre




IDÉE DIRECTRICE

L'architecture gagnante n'est pas la plus autonome. C'est celle qui place le bon niveau d'autonomie entre un contexte maîtrisé, des outils gouvernés et des preuves vérifiables.

Le paysage en une page

Six archétypes d'exécution, à combiner avec une topologie de déploiement et un socle de contrôle commun.




RECOMMANDATION PAR DÉFAUT

Commencer par un pipeline déterministe avec validations humaines, puis ouvrir des boucles agentiques seulement sur les tâches ambiguës. Mutualiser très tôt identité, contexte, outils, évaluations et traçabilité.


Repères : DORA 2025 [1], Anthropic [2], OpenAI [3].

Ce que l'on appelle une usine logicielle IA

Un système socio-technique qui transforme une intention produit en logiciel exploitable, avec l'IA comme moteur de décision ou d'exécution.



La différence architecturale tient à la place où l'IA prend la décision.



Trois axes à ne pas confondre

AUTONOMIE	Qui choisit la prochaine action ?	humain > code > modèle
TOPOLOGIE	Où s'exécutent agents et modèles ?	SaaS > cloud privé > hybride
PORTÉE	Quelle partie du cycle est couverte ?	tâche > produit > portefeuille

Choisir selon l'incertitude et l'échelle

Plus la tâche est ambiguë, plus l'agent apporte de la valeur. Plus l'échelle augmente, plus le plan de contrôle devient critique.



LECTURE

La plateforme agentique n'est pas un niveau de maturité obligatoire. C'est un choix d'industrialisation lorsque plusieurs équipes, modèles et agents partagent les mêmes contrôles.

SDLC assisté

L'IA augmente les personnes dans les outils qu'elles utilisent déjà.

AUTONOMIE FAIBLE

DÉPLOIEMENT RAPIDE

RISQUE MAÎTRISABLE



Le flux reste humain. L'IA accélère une tâche sans posséder le workflow.

PROMESSE

Accélérer l'écriture, la compréhension et la revue sans modifier la chaîne de responsabilité.

ADAPTÉ À

- Adoption initiale à grande échelle
- Équipes avec CI/CD déjà mature
- Tâches locales et interactives

POINTS DE VIGILANCE

- Fuite de contexte ou de secrets
- Code plausible mais non vérifié
- Mesure de productivité trompeuse

DÉCISIONS CLÉS

- Sources de contexte autorisées
- Règles de revue et d'attribution
- Télémétrie respectueuse des équipes

Repères : DORA [1].

Pipeline déterministe enrichi par IA

Le workflow reste codé ; l'IA intervient comme une étape spécialisée.

PRÉDICTIBLE

AUDITABLE

COMPOSABLE



ENTRÉES / SORTIES STRUCTURÉES | PORTES DE QUALITÉ | REPRISES EXPLICITES

Chaque appel IA est une étape remplaçable et observable

PROMESSE

Insérer génération, classification ou synthèse dans une chaîne CI/CD avec contrats et portes de qualité.

ADAPTÉ À

- Modernisation structurée
- Génération de tests ou documentation
- Contrôle réglementaire fort

POINTS DE VIGILANCE

- Propagation d'une mauvaise sortie
- Rigidité des contrats
- Latence cumulée des étapes

DÉCISIONS CLÉS

- Schémas d'entrée / sortie
- Seuils et stratégie de repli
- Idempotence et reprise

Repères : Anthropic [2], Google MLOps [4].

Agent unique en boucle contrôlée

Un agent planifie et agit dans un environnement borné jusqu'à preuve ou arrêt.

FLEXIBLE

BAC À SABLE

BOUCLE COURTE



PROMESSE

Automatiser une tâche complexe sur un dépôt sans introduire immédiatement une orchestration distribuée.

ADAPTÉ À

- Migration ciblée
- Correction de défauts
- Prototypage et maintenance

POINTS DE VIGILANCE

- Boucles longues ou erratiques
- Sélection du mauvais outil
- Modification hors périmètre

DÉCISIONS CLÉS

- Budget de tours et temps
- Critères de succès exécutables
- Diff, tests et rollback

Repères : OpenAI [3], Anthropic [2].


Multi-agent hiérarchique

Un orchestrateur délègue à des spécialistes puis consolide les preuves.

SPÉCIALISÉ

PARALLÉLISABLE

COORDONNÉ



PROMESSE

Traiter des travaux hétérogènes en séparant compétences, outils et contextes tout en gardant un point de contrôle.

ADAPTÉ À

- Grands changements multi-domaines
- Revue croisée code / sécurité
- Portefeuille de tâches complexe

POINTS DE VIGILANCE

- Coût et latence multipliés
- Contexte divergent
- Erreurs de délégation

DÉCISIONS CLÉS

- Contrats entre agents
- Propriété de l'état partagé
- Arbitrage des contradictions

Repères : OpenAI [3], Anthropic [2].


Agents événementiels et persistants

Des cellules autonomes réagissent aux événements du cycle de vie logiciel.

ASYNCHRONE

RÉACTIF

HAUT DÉBIT



PROMESSE

Passer d'une assistance à la demande à une usine qui surveille, priorise et traite continuellement le travail.

ADAPTÉ À

- Triage d'issues et alertes
- Mises à jour de dépendances
- Remédiation récurrente

POINTS DE VIGILANCE

- Tempêtes d'événements
- Effets de bord dupliqués
- Dérive d'agents persistants

DÉCISIONS CLÉS

- Files durables et idempotence
- Déduplication et quarantaine
- SLO par type d'événement

Repères : OpenTelemetry [8], NIST [5].

Plateforme agentique mutualisée

Un plan de contrôle commun alimente plusieurs produits, équipes et runtimes.

MUTUALISÉ

MULTI-MODÈLES

À L'ÉCHELLE

EXPÉRIENCES

IDE | portail | API | chat

RUNTIME AGENTIQUE

orchestration | mémoire | exécution

PLAN DE CONTRÔLE

identité | politique | évaluation | coûts

OUTILS & CONTEXTE

SCM | CI/CD | tickets | docs | cloud

PROMESSE

Standardiser les capacités transverses sans imposer un workflow unique aux équipes produit.

ADAPTÉ À

- DSI multi-produits
- Plusieurs fournisseurs de modèles
- Besoins de conformité communs

POINTS DE VIGILANCE

- Plateforme trop précoce
- Couplage au runtime
- Goulot d'étranglement central

DÉCISIONS CLÉS

- Produits plateforme explicites
- API et outils versionnés
- Chargeback et SLO

Repères : DORA [1], MCP [6].

Architecture de référence en quatre plans

Quel que soit l'archétype, la robustesse vient de la séparation entre expérience, exécution, connaissance et contrôle.

01

PLAN D'EXPÉRIENCE

IDE, portail développeur, API, chatops



02

PLAN D'EXÉCUTION

orchestrateur, agents, files, sandboxes



03

PLAN DE CONNAISSANCE

code, docs, graphe, RAG, mémoire



04

PLAN DE CONTRÔLE

IAM, politiques, evals, télémétrie, coûts

RÈGLE STRUCTURANTE

Aucun agent ne parle directement à une ressource sensible. Toute action passe par un outil typé, authentifié, journalisé et soumis à une politique.

MCP illustre une approche client-serveur pour exposer outils, ressources et prompts ; il ne remplace ni l'autorisation, ni l'isolation, ni la gouvernance.

Repères : Model Context Protocol [6], OpenAI [3], OpenTelemetry [8].

Quatre topologies, indépendantes de l'orchestration

La même usine peut être assistée, pipeline ou multi-agent, tout en étant SaaS, privée, hybride ou souveraine.

A

SaaS managé

Modèles et runtime chez un fournisseur. Mise en route rapide, élasticité forte.

À CADRER

Vérifier résidence, rétention, contrats, identité et export des traces.

B

Cloud privé

Runtime dans le compte cloud de l'entreprise ; modèles via API ou endpoints privés.

À CADRER

Bon compromis pour gouverner réseau, secrets, observabilité et coûts.

C

Hybride

Contexte et exécution sensibles en interne ; routage vers plusieurs modèles.

À CADRER

Exige un model gateway, une classification des données et des stratégies de repli.

D

Souveraine / isolée

Modèles et runtime on-premise ou réseau fermé.

À CADRER

Contrôle maximal, mais charge d'exploitation, capacité GPU et mise à jour plus lourdes.

PRINCIPE

Router par niveau de sensibilité et capacité requise, pas uniquement par coût unitaire du modèle.

Matrice des six archétypes

Notation relative de 1 (faible) à 5 (fort). Le score est un signal de conception, pas un classement universel.

ARCHÉTYPE	AUTON.	PRÉDICT.	ÉCHELLE	COÛT OPS	RISQUE
1 SDLC assisté	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●
2 Pipeline IA	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●
3 Agent unique	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●
4 Multi-agent	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●
5 Événementiel	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●
6 Plateforme	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●	● ● ● ● ●

COMMENT LIRE

- La prédictibilité chute quand le modèle choisit librement la séquence d'actions.
- Le coût opérationnel inclut observabilité, files, reprises, évaluations et expertise plateforme.
- La plateforme devient pertinente quand la mutualisation compense sa complexité.

ANTI-RACCOURCI

Un score d'autonomie élevé ne signifie pas une meilleure architecture. La valeur vient du ratio résultat vérifié / coût total / risque résiduel.

Sécurité et gouvernance par couches

Les garde-fous de contenu ne remplacent jamais les contrôles de sécurité classiques.

IDENTITÉ & AUTORISATION

moindre privilège, identité de charge, jetons courts

OUTILS & DONNÉES

schémas typés, allowlist, secrets, classification

EXÉCUTION

sandbox, réseau filtré, quotas, actions réversibles

MODÈLE

filtres, politiques, défense contre injection, sorties validées

SUPERVISION

preuves, approbations, audit, bouton d'arrêt

APPROBATION BASÉE SUR LE RISQUE

Lecture seule et réversible : automatique. Écriture contrôlée : politique + preuve. Action sensible ou irréversible : approbation humaine explicite.

Repères : NIST AI RMF [5], OpenAI guardrails [3], SLSA [7], OWASP [9].

Évaluer avant d'optimiser

L'unité d'observation n'est plus seulement le déploiement : c'est l'exécution complète d'une tâche, avec ses décisions, outils et preuves.



Q

qualité de sortie vérifiée

T

temps jusqu'à preuve

€

coût complet par tâche

R

risque / reprise humaine


TABLEAU DE BORD MINIMAL

Taux de succès sans reprise | précision des changements | tests passés | vulnérabilités | tours par tâche | coût tokens + compute | temps humain économisé | incidents évités

Repères : OpenTelemetry [8], Anthropic sur les évaluations [10].

Un arbre de choix pragmatique

Partir du flux de valeur et du risque, puis augmenter l'autonomie par preuve.



À TOUT MOMENT : si le risque n'est pas contrôlable, réduire l'autonomie ou réintroduire une approbation.

Recommandations par contexte

Les combinaisons ci-dessous sont des points de départ raisonnables, à confirmer par expérimentation.

ÉQUIPE PRODUIT DE 10 À 30 PERSONNES

SDLC assisté + pipeline IA

Priorité à l'adoption, aux tests et à la revue. Agent unique en bac à sable pour les tâches longues.

DSI MULTI-PRODUITS

Plateforme légère + agents spécialisés

Mutualiser gateway modèles, outils, politiques, evals et télémétrie. Laisser les workflows aux équipes.

LEGACY CRITIQUE

Pipeline déterministe + hybride

Contexte interne, génération bornée, preuves fortes, approbation obligatoire avant modification ou livraison.

PRODUIT CLOUD-NATIVE À FORT DÉBIT

Événementiel + agent unique

Agents activés par issues, alertes et dépendances ; files durables et idempotence indispensables.

ENVIRONNEMENT RÉGLEMENTÉ / SOUVERAIN

Hybride ou isolé + faible autonomie

Routeage par sensibilité, journal d'audit, modèles validés et action humaine sur les opérations sensibles.

SIGNAL D'ALERTE

Si l'équipe ne peut pas expliquer comment annuler une action, reproduire une exécution et mesurer sa qualité, l'autonomie est déjà trop élevée.

Une feuille de route en 180 jours

Industrialiser les preuves avant d'industrialiser l'autonomie.

1

0-30 J

CADRER

2 flux de valeur, baseline DORA, classes de données, politiques outils.

2

31-60 J

PROUVER

Pipeline IA ou agent unique ; evals de référence ; sandbox ; revue humaine.

3

61-90 J

FIABILISER

Traces de bout en bout, reprise, budgets, tests adversariaux, runbooks.

4

91-180 J

ÉTENDRE

Catalogue d'outils, gateway modèles, plateforme légère, nouveaux produits.

CRITÈRE DE PASSAGE

Étendre seulement si la qualité est mesurable, les actions sont gouvernées, la reprise est testée et le coût complet reste inférieur à la valeur créée.

Qui possède quoi ?

La plateforme fournit les rails. Les équipes produit restent responsables du résultat et du risque métier.

ÉQUIPE PRODUIT

cas d'usage, critères d'acceptation, evals métier, expérience

PLATEFORME

runtime, modèles, outils, sandbox, observabilité, coûts

SÉCURITÉ / RISQUES

politiques, classes d'actions, audit, tests adversariaux

DATA / CONNAISSANCE

qualité des sources, index, droits, cycle de vie

SRE / EXPLOITATION

SLO, incidents, capacité, reprise, runbooks

CONTRAT DE SERVICE DE L'AGENT

But autorisé | outils permis | données accessibles | budget | condition d'arrêt | critères de succès | preuves attendues
| escalade humaine

Revue d'architecture avant mise en production

Vingt questions courtes pour éviter les angles morts les plus coûteux.

VALEUR

- ☐ Le flux cible et sa baseline sont-ils mesurés ?
- ☐ L'IA traite-t-elle une vraie ambiguïté ?
- ☐ Le résultat attendu est-il testable ?
- ☐ Le coût complet est-il plafonné ?

CONTRÔLE

- ☐ Chaque outil est-il typé et versionné ?
- ☐ Les droits suivent-ils le moindre privilège ?
- ☐ Les actions sensibles exigent-elles approbation ?
- ☐ L'arrêt et l'annulation sont-ils testés ?

QUALITÉ

- ☐ Un jeu d'evals représentatif existe-t-il ?
- ☐ Les non-régressions sont-elles automatisées ?
- ☐ Les preuves sont-elles attachées à la tâche ?
- ☐ Les erreurs déclenchent-elles une reprise sûre ?

EXPLOITATION

- ☐ Une exécution est-elle traçable de bout en bout ?
- ☐ Les limites de tours, temps et tokens existent-elles ?
- ☐ Les SLO et alertes sont-ils définis ?
- ☐ Un runbook d'incident est-il disponible ?

GOUVERNANCE

- ☐ Les données sont-elles classifiées et minimisées ?
- ☐ Les modèles et prompts sont-ils versionnés ?
- ☐ Les responsabilités sont-elles explicites ?
- ☐ Les journaux ont-ils une durée de conservation ?

Les termes indispensables

Des définitions volontairement opérationnelles pour aligner architecture, produit et risques.

AGENT

Système où un modèle choisit dynamiquement des actions et outils pour atteindre un but.

WORKFLOW IA

Chemin d'exécution prédéfini qui appelle un ou plusieurs modèles à des étapes connues.

ORCHESTRATEUR

Composant qui distribue le travail, maintient l'état et applique les règles d'exécution.

OUTIL

Interface typée permettant à un agent de lire une donnée ou d'agir sur un système.

CONTEXTE

Informations minimales nécessaires à la décision : code, documentation, état, politiques.

RAG

Recherche de passages pertinents puis injection dans le contexte du modèle.

EVAL

Test reproductible mesurant qualité, sécurité ou conformité d'une sortie ou trajectoire.

TRACE

Chronologie corrélée d'une exécution : modèle, appels outils, décisions, coûts et résultats.

SANDBOX

Environnement isolé, éphémère et limité où l'agent peut exécuter des actions.

MODEL GATEWAY

Point d'accès commun pour router, sécuriser, mesurer et optimiser les appels modèles.

PLAN DE CONTRÔLE

Services transverses : identité, politiques, budgets, observabilité et évaluation.

PREUVE

Artefact vérifiable : tests, diff, rapport de scan, journal ou approbation.

Sources et prolongements

Sources consultées le 30 août 2026. Les archétypes et recommandations de ce dossier constituent une synthèse originale.

[1] DORA - State of AI-assisted Software Development 2025

L'IA agit comme amplificateur du système organisationnel existant.

[2] Anthropic - Building effective agents

Distinction workflows / agents et patrons composites.

[3] OpenAI - A practical guide to building agents

Agent unique, multi-agent, outils, orchestration et garde-fous.

[4] Google Cloud - MLOps: continuous delivery and automation

Pipelines, validation et niveaux d'automatisation.

[5] NIST - AI Risk Management Framework

Cadre volontaire pour intégrer la confiance au cycle de vie IA.

[6] Model Context Protocol - Architecture overview

Architecture client-serveur pour outils, ressources et prompts.

[7] SLSA v1.1 - Security levels

Repères de sécurité et de provenance de la chaîne de production.

[8] OpenTelemetry - Observability primer

Traces, métriques et logs pour comprendre les systèmes distribués.

[9] OWASP - Top 10 for LLM Applications

Risques applicatifs des systèmes fondés sur les grands modèles.

[10] Anthropic - Demystifying evals for AI agents

Conception d'évaluations pour les agents multi-tours.

FIN DU DOSSIER | UTILISER LA TYPOLOGIE COMME UN OUTIL DE CONVERSATION, PAS COMME UNE TAXONOMIE FIGÉE